

# Estatística Numérica Computacional

## Trabalho nº1

Marta Paz nº49861  
Rafael Almeida nº49788  
Rafael Gameiro nº50677  
Ricardo Pinto nº49811

October, 2018

## Exercício 1

Considere a variável aleatória  $X$  com função densidade de probabilidade

$$f(x) = \begin{cases} 3x^2, & 0 < x < 1 \\ 0, & \text{para outros valores de } x \end{cases}$$

Considere agora a variável aleatória  $Y = g(X)$ , sendo  $g(x) = \log(2x^2 + 3)$ . Estime  $P(1 < Y < 1.5)$  usando o método de Monte Carlo e apresente também o desvio padrão da estimativa.

### Resolução

1. Sabendo que  $0 < x < 1$ , pelo ramo da função onde  $x$  varia, e que  $g$  é crescente (isto porque a função logarítmica cresce ao tender para mais infinito), então podemos concluir que  $g(0) < g(X) < g(1)$ . De outro modo, substituindo as expressões pelos seus valores respetivos, temos:  $1,099 < Y < 1,61$ . Assim:

$$\begin{aligned} P(1 < Y < 1.5) &= P(1 < Y < 1.099) + P(1.099 < Y < 1.61) \\ &= 0 + P(1.099 < Y < 1.61) = P(g^{-1}(1.099) < X < g^{-1}(1.61)) \end{aligned}$$

2. De seguida, calculámos o valor de  $g^{-1}(x)$ :

$$\begin{aligned} y = \log(2x^2 + 3) &\Leftrightarrow e^y = 2x^2 + 3 \Leftrightarrow x^2 = \frac{e^y - 3}{2} \\ &\Leftrightarrow x = \sqrt{\frac{e^y - 3}{2}} \Leftrightarrow g^{-1}(x) = \sqrt{\frac{e^y - 3}{2}} \end{aligned}$$

3. Ficamos, assim, com o integral,

$$\int_{g^{-1}(1.099)}^{g^{-1}(1.61)} f(x) dx$$

onde aplicámos o método de Monte Carlo em R.

```

1 #Exercicio 1
2 #numero de amostras
3 n=10000
4
5 invertg <- function(x){
6   sqrt((exp(1)^x)-3)/sqrt(2)
7 }
8
9 #limites
10 a <- invertg(1.099)
11 b <- invertg(1.5)
12
13 func <- function(x){
14   if (0 < x && x < 1){
15     3*x^2
16   } else 0
17 }
18
19 u = runif(n, min =a, max = b)
20
21 amostra <- 1:n
22 for (i in 1:n){
23   amostra[i] <- func(u[i])
24 }
25 prob <- (b-a)*mean(amostra)
26 sd <- sd(amostra)
27 hist(amostra)
28

```

R:  $P(1 < Y < 1.5) \approx 0.64$        $sd \approx 0.66$

## Exercício 2

Sejam  $X$  e  $Y$  duas variáveis aleatórias independentes ambas com função densidade de probabilidade,  $f(x) = \frac{2}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}}$ ,  $0 < x < +\infty$ , (ou seja, estas variáveis são o valor absoluto de uma normal standart) e seja  $\theta = E(e^{X+Y})$ .

a) Use o método de Monte Carlo para estimar  $\theta$ , usando variáveis aleatórias com distribuição  $Unif(0, 1)$ .

### Resolução

Para este exercício, efetuámos uma mudança de variável para que o integral que queremos calcular que é:

$$\int_0^{+\infty} \int_0^{+\infty} e^{x+y} dx dy$$

Para que o domínio de integração esteja entre 0 e 1, fizemos a seguinte conta:

$$u = \frac{1}{x+1} \Leftrightarrow (x+1)u = 1 \Leftrightarrow (x+1) = \frac{1}{u} \Leftrightarrow x = \frac{1}{u} - 1 \Leftrightarrow x = \frac{1-u}{u}$$

$$u(0) = \frac{1}{0+1} = 1 = b$$

$$u(+\infty) = \frac{1}{+\infty+1} = 0 = a$$

**Nota:** a mudança de variável para o y é igual à de x, mas como x e y são variáveis independentes tem-se de usar uma letra diferente

$$\int_0^1 \int_0^1 e^{\left(\frac{2}{\sqrt{2\pi}} \cdot e^{-\frac{\left(\frac{(1-u)}{u}\right)^2}{2}}\right)} \cdot e^{\left(\frac{2}{\sqrt{2\pi}} \cdot e^{-\frac{\left(\frac{(1-t)}{t}\right)^2}{2}}\right)} \cdot -\frac{1}{u^2} \cdot -\frac{1}{t^2} du dt$$

Como não conseguimos calcular este integral analiticamente vamos recorrer ao método de Monte Carlo para calcular uma estimativa para o seu valor.

Para tal, fizemos os seguintes passos em R:

1. Criámos uma função auxiliar que nos vai dar a fórmula da expressão que queremos calcular o estimador, e consequentemente, o integral
2. Criámos uma amostra aleatória para o valor de x e outra para o valor de y
3. Em seguida, calculámos o valor da expressão com os valores aleatórios e obtivemos o resultado do estimado, calculando a média de todos os valores

```

30 #Exercicio 2 - alinea a)
31 a <- 0                                #limite inferior
32 b <- 1                                #limite superior
33
34 n <- 1000                             #numero de amostras
35
36 func <- function(x,y){                #funcao a analisar
37   u = 1/(x+1)                          #mudancas de variaveis
38   v = 1/(y+1)
39
40   auxX= (2/sqrt(2*pi))*exp(-(((1-u)/u)^2)/2)
41   auxY= (2/sqrt(2*pi))*exp(-(((1-v)/v)^2)/2)
42
43   exp(auxX+auxY) * -1/(u^2) * -1/(v^2)
44 }
45
46
47 resultArea <- 1:n
48 amostra <- 1:n
49 xRand = runif(min=a,max=b,n=n)
50 yRand = runif(min=a,max=b,n=n)
51
52 for(j in 1:n){
53   amostra[j] = func(xRand[j],yRand[j])
54 }
55
56 mean(amostra)                          #valor esperado
57 sd(amostra)                           #desvio padrão
58

```

R:  $\approx 20.16$

b) Reestime o parâmetro  $\theta$  através do método de Monte Carlo usando agora variáveis aleatórias com outra distribuição, uma distribuição que considere adequada.

### Resolução

1. Para este exercício, considerámos que a distribuição mais adequada para calcular as variáveis aleatórias seria utilizar a distribuição normal, uma vez que duas vezes a função densidade de probabilidade da normal é igual à função densidade de probabilidade das variáveis  $X$  e  $Y$ .

2. Assim sendo, no R, geramos 1000 valores aleatórios com distribuição uniforme para duas variáveis diferentes e de seguida aplicámos a transformação de Box-Muller para obtermos distribuições normais. Depois, para cada valor gerado nas duas variáveis anteriores, calculámos  $\exp(Xi + Yi)$ .

```

1 a <- 0 #limite inferior no caso da distribuicao normal e a media
2 b <- 1 #limite superior no caso da distribuicao normal e a variancia
3
4 n <- 1000 #numero de amostras
5
6 #nao e preciso meter aqui a funcao pois variaveis geradas sobre essa funcao ja sofrem a funcao utilizada
7
8 amostra <- 1:n
9 #for (i in 1:n){
10 xRand = runif(min=0, max=1, n) #amostra de 1000 elementos entre a e b (esta dentro do for pois vamos mudar os valores por ca
11 yRand = runif(min=0, max=1, n)
12
13
14 func <- function(x){
15   2*x
16 }
17
18 #gerar uma amostra que segue a distribuicao normal a partir de 2 amostras q seguem uma distribuicao uniforme
19 z1 = sqrt(-2*log(xRand))*cos(2*pi*yRand)
20 z2 = sqrt(-2*log(xRand))*sin(2*pi*yRand)
21
22
23 for(j in 1:n){
24   amostra[j] = exp(func(z1[j]) + func(z2[j]))
25 }
26
27 mean(amostra) #valor esperado
28 sd(amostra) #desvio padrão
29 hist(amostra) #histograma
30

```

R:  $\theta \approx 35.6$

c) Considere o estimador de Monte Carlo da alínea (a),  $\hat{\theta}$  e seja  $C = \overline{UV}$ , ou seja,  $C = \frac{1}{N} \sum_{i=1}^n U_i V_i$  uma variável de controlo, em que  $U$  e  $V$  são variáveis aleatórias com distribuição  $\text{Unif}(0,1)$ . Reestime  $\theta$  usando esta variável de controlo. Estime o desvio-padrão e compare os desvios-padrão dos dois estimadores. Discuta os resultados numéricos e analíticos.

## Resolução

1. Para resolver este exercício, utilizámos a seguinte fórmula para reestimar a variável

$$\hat{\theta}_c = \hat{\theta} - \beta * (C - E(u))$$

2. Para tal, utilizámos parte do código feito no exercício (a) e gerámos uma variável de controle apartir da função `generateControl` implementada no R.

3. De seguida, tivemos de calcular um  $\beta$ . Para calcular este valor, usámos a seguinte fórmula:

$$\beta = \frac{Cov(\hat{\theta}, C)}{Var(c)}$$

Para calcular o beta, criámos uma função no R, que calcula a covariância entre a variável de controle dada e a amostra calculada do exercício a). Para além do cálculo da covariância, também tivemos de calcular a variância da variável de controle, C.

4. De seguida, gerámos uma nova amostra seguindo a seguinte formula:

$$finalC[i] = amostra[i] - (\beta * (c[i] - mean(c)))$$

5. A média dessa amostra é o estimador que queremos calcular que terá o seguinte valor:  $\hat{\theta}_c = 19.98$

6. O valor do desvio padrão de  $\hat{\theta}_c = 8.014776$  e o valor do desvio padrão de  $\hat{\theta} = 8.017608$ , sendo que obtivemos o mesmo valor para o valor do estimador.

7. Comparando os valores apresentados no ponto 6, podemos verificar que, usando a variável de controlo, o valor do estimador fica igual ao valor do estimador quando não utilizávamos a variável de controlo, mas, em contrapartida, o valor do desvio padrão desce ligeiramente quando o estimador é calculado com a variável de controlo. Assim, podemos concluir que o cálculo de um estimador é mais preciso e/ou as variáveis aleatórias geradas estão mais próximas do valor real.

```

88
89 #Exercicio 2 - alinea c)
90 a <- 0
91 b <- 1
92
93 n <- 1000
94
95
96 func <- function(x,y){
97   u = 1/(x+1)
98   v = 1/(y+1)
99
100   auxX= (2/sqrt(2*pi))*exp(-(((1-u)/u)^2)/2)
101   auxY= (2/sqrt(2*pi))*exp(-(((1-v)/v)^2)/2)
102
103   exp(auxX+auxY) * -1/(u^2) * -1/(v^2)
104 }
105
106 generateVarControl <- function(){
107   nctrl = 1000
108   c = runif(min=0, max=1, nctrl)
109   v = runif(min=0, max=1, nctrl)
110
111   aux <- 1:nctrl
112   for (i in 1:nctrl){
113     aux[i] = c[i]*v[i]
114   }
115   aux
116 }
117
118 resultArea <- 1:n
119 amostra <- 1:n
120 xRand = runif(min=a,max=b,n=n)
121
122
123 for(j in 1:n){
124   amostra[j] = func(xRand[j],yRand[j])
125 }
126
127 c = generateVarControl()
128 teta_chapeu = amostra
129 beta = cov(x=teta_chapeu, y=c)/var(c)
130
131 finalC = 1:n
132 for(i in 1:n){
133   finalC[i]=amostra[i] - (beta*(c[i]-mean(c)))
134 }
135
136 sd(amostra)
137 mean(amostra)
138
139 sd(finalC)
140 mean(finalC)

```

#limite inferior  
 #limite superior  
 #numero de amostras  
 #funcao a analisar  
 #mudanca de variavel  
 #mudança de variavel  
 #funcao que gera a amostra de controlo  
 #amostra de 1000 elementos entre a e b  
 #amostra de controlo  
 #valores tirado do exercio 2a)  
 #beta minimo  
 #geracao da amostra final usando a variavel de controlo  
 #sd inicial  
 #estimador inicial  
 #sd final  
 #estimador final